

MÁSTER EN BIG DATA, DATA SCIENCE
E INTELIGENCIA ARTIFICIAL

Sistema inteligente para el análisis, comparación y evaluación de cobertura documental mediante RAG y bases vectoriales

Prototipo local con BGE, ChromaDB, Qwen, SQLite y Streamlit

AUTOR/A	Maria Alejandra Romero Gutierrez
TUTOR/A	Carlos Ortega y Santiago Mota
MODALIDAD	Proyecto técnico de software / Opción 3
CURSO ACADÉMICO	Máster en big data, data science e inteligencia artificial modalidad online

Repositorio técnico: github.com/Alejandra-Romero-G/TFM_Documental_AI · versión v1.0.0

Índice de contenidos

Índice de contenidos	2
Resumen ejecutivo	1
1. Introducción	2
1.1. Contexto y problema	2
1.2. Objetivos	2
1.3. Alcance y exclusiones	2
2. Fundamentos de la solución	3
2.1. Representación semántica y embeddings	3
2.2. Base vectorial y recuperación	3
2.3. Generación aumentada por recuperación	3
2.4. Similitud y cobertura documental	4
3. Corpus, calidad y procedencia	4
3.1. Fuentes documentales	4
3.2. Auditoría y corpus canónico	4
3.3. Calidad, derechos y reproducibilidad	4
4. Metodología y arquitectura	5
4.1. Vista general	5
4.2. Preparación de los documentos	5
4.3. Indexación y recuperación	5
4.4. Ingesta dinámica y consistencia	6
4.5. Trazabilidad y controles contra respuestas no fundamentadas	6
5. Implementación y experiencia de uso	6
5.1. Componentes principales	6
5.2. Interfaz Streamlit	7
5.3. Preguntas documentales	7
5.4. Comparación de documentos	8
5.5. Preevaluación de cobertura	8
6. Evaluación	9
6.1. Diseño experimental	9
6.2. Resultados del retrieval	9
6.3. Resultados de respuestas RAG	10
6.4. Interpretación conjunta	10
7. Discusión	11
7.1. Aportaciones	11
7.2. Limitaciones y amenazas a la validez	11
7.3. Consideraciones éticas y de uso responsable	11

8. Conclusiones y líneas futuras.....	11
Bibliografía y referencias	12
Anexos	1
Anexo C. Evidencias y artefactos.....	5
Anexo D. Capturas de la interfaz y ejemplos de funcionamiento	6
Anexo E. Enlaces a los entregables digitales	10

Resumen ejecutivo

Este Trabajo Fin de Máster presenta un sistema local para convertir colecciones de documentos PDF en evidencia consultable, comparable y trazable. El prototipo responde a una necesidad frecuente en organizaciones que manejan manuales, informes y documentación preventiva: localizar información relevante con rapidez sin perder la referencia al archivo y a la página de origen. La solución combina recuperación semántica y generación aumentada por recuperación (RAG), y añade controles específicos para la deduplicación, el aislamiento documental y la exportación de resultados.

El trabajo parte de 173 PDF procedentes de fuentes OSHA y NIOSH. Una auditoría inicial detectó 93 duplicados binarios y cuatro problemas de extracción, lo que permitió construir un corpus canónico de 78 documentos y 8.828 fragmentos indexados. Los textos se extraen por página, se dividen en fragmentos solapados y se representan mediante BAAI/bge-base-en-v1.5. ChromaDB almacena los vectores y metadatos, mientras que Qwen/Qwen2.5-3B-Instruct genera respuestas basadas únicamente en las evidencias recuperadas. Streamlit proporciona una interfaz para cargar, consultar, comparar y preevaluar documentos.

La evaluación documental obtuvo Hit@1 de 90,91 %, Hit@3 y Hit@5 del 100 %, MRR@5 de 0,9545 y una latencia media de retrieval de 0,0927 segundos. En seis casos de evaluación RAG se alcanzó un 95 % de cobertura conceptual media, 100 % de aislamiento documental, validez de etiquetas de fuente y abstención correcta. La generación local en CPU presentó una latencia media de 113,92 segundos, que constituye la principal limitación operativa. Los resultados respaldan la viabilidad del prototipo como herramienta de apoyo documental, pero no como mecanismo de certificación legal o normativa.

Palabras clave: generación aumentada por recuperación (RAG); análisis documental; embeddings; bases de datos vectoriales; recuperación semántica; trazabilidad documental.

1. Introducción

1.1. Contexto y problema

Las organizaciones acumulan cada vez más documentación en formato PDF: normas internas, guías técnicas, manuales de seguridad, informes y procedimientos. La información puede estar repartida entre documentos extensos, repetidos o con distintas versiones. Una búsqueda literal ayuda cuando se conoce la palabra exacta, pero resulta insuficiente cuando una misma idea aparece redactada de formas diferentes. El problema no consiste solo en encontrar texto, sino en recuperar evidencia útil y demostrar de dónde procede.

Los modelos de lenguaje facilitan la síntesis y la interacción en lenguaje natural, aunque una respuesta fluida no garantiza que esté respaldada por la documentación seleccionada. La arquitectura RAG reduce este riesgo al recuperar primero fragmentos relevantes y utilizar después ese contexto para generar la respuesta [1]. Para que el enfoque sea útil en un escenario documental, deben añadirse controles sobre duplicados, selección de documentos, identificación de páginas, conservación de metadatos y validación de las fuentes citadas.

El prototipo del proyecto desarrollado aborda este reto desde una perspectiva de producto técnico local. No se limita a un experimento aislado de similitud: incorpora un pipeline reproducible para auditar e indexar un corpus, una interfaz de usuario, una ingesta dinámica de nuevos PDF, comparaciones entre documentos, preevaluaciones de cobertura y evaluaciones automáticas del retrieval y de la respuesta generada.

1.2. Objetivos

El objetivo general es desarrollar y validar un sistema local de análisis documental capaz de recuperar evidencia semánticamente relevante y presentarla con trazabilidad hasta el documento, la página y el fragmento de origen.

Los objetivos específicos son:

- Auditar el corpus, detectar duplicados binarios y textuales e identificar documentos con problemas de extracción.
- Construir un corpus canónico y un índice vectorial persistente con embeddings normalizados.
- Responder preguntas sobre todo el corpus o sobre documentos seleccionados, mostrando fuentes verificables.
- Comparar exactamente dos documentos y localizar coincidencias o evidencias diferenciales.
- Preevaluar la presencia de evidencia respecto de un documento de referencia sin confundirla con cumplimiento legal.
- Permitir la incorporación de nuevos PDF con control de duplicados, rollback y registro persistente.
- Ofrecer las funciones principales mediante una interfaz Streamlit y exportar resultados reutilizables.
- Evaluar de forma reproducible el ranking documental, el grounding, el aislamiento y la abstención.

1.3. Alcance y exclusiones

El alcance se limita al análisis de documentos PDF con texto extraíble y a un corpus en inglés sobre seguridad y salud ocupacional. El sistema ayuda a localizar, resumir y relacionar evidencias. No verifica que una organización haya implantado realmente una medida, no interpreta jurídicamente una norma y no sustituye la revisión de una persona competente. Los PDF escaneados se detectan

y marcan como pendientes de OCR, pero la ejecución automática de OCR queda fuera de esta versión.

NOTA SOBRE EL ALCANCE DEL ANÁLISIS

El análisis de cobertura identifica la presencia de evidencia textual en los documentos seleccionados. No verifica la aplicación efectiva de las medidas descritas ni permite determinar el cumplimiento legal o normativo. Por tanto, sus resultados deben interpretarse únicamente como apoyo al análisis documental y no constituyen asesoría, auditoría ni certificación legal.

2. Fundamentos de la solución

2.1. Representación semántica y embeddings

Un embedding representa un texto como un vector numérico. Textos con significados próximos tienden a ocupar posiciones cercanas en ese espacio, aunque no compartan exactamente las mismas palabras. El proyecto utiliza BAAI/bge-base-en-v1.5, perteneciente a la familia BGE descrita en C-Pack [2]. El modelo genera vectores de 768 dimensiones y se integra mediante sentence-transformers.

Los embeddings se normalizan para que la similitud coseno pueda calcularse de forma coherente. En las consultas se aplica la instrucción recomendada para tareas de recuperación BGE. La decisión de usar BGE en la versión final se apoya tanto en su adecuación para retrieval en inglés como en la evaluación realizada sobre el corpus del proyecto.

2.2. Base vectorial y recuperación

ChromaDB mantiene una colección persistente que reúne el vector, el texto del fragmento y sus metadatos. Los metadatos incluyen el identificador documental, el archivo, la página, el índice del fragmento, la ruta relativa y el modelo empleado. Esta combinación permite recuperar por similitud y, al mismo tiempo, filtrar la búsqueda por uno o varios documentos [4].

La función de retrieval recupera más candidatos de los que finalmente se muestran. Después elimina IDs repetidos y limita el número de fragmentos por documento. Esta estrategia evita que un PDF extenso monopolice todas las posiciones y permite evaluar el ranking a nivel documental.

2.3. Generación aumentada por recuperación

En RAG, la consulta del usuario activa dos etapas: recuperación y generación. La primera selecciona fragmentos relacionados; la segunda recibe únicamente esas evidencias y redacta la respuesta. El diseño del prompt exige etiquetas [S1], [S2] y una lista de fuentes utilizadas. La aplicación presenta la respuesta del modelo junto con una tabla construida de forma determinista a partir de los metadatos de ChromaDB. Así, la fuente mostrada no depende de que el modelo recuerde correctamente un nombre o una página.

El modelo generativo es Qwen/Qwen2.5-3B-Instruct, ejecutado localmente mediante transformers. Qwen2.5 incorpora mejoras en seguimiento de instrucciones y contexto largo respecto de generaciones anteriores [3]. La elección de una versión de tres mil millones de parámetros busca mantener un equilibrio entre capacidad y posibilidad de ejecución local, aunque la latencia en CPU sigue siendo elevada.

2.4. Similitud y cobertura documental

La comparación documental resume dos PDF y calcula una similitud global sobre las evidencias recuperadas. También identifica pares de fragmentos próximos y evidencia potencialmente diferencial. La preevaluación de cobertura parte de evidencias de un documento de referencia y busca su mejor correspondencia en un documento evaluado. Los estados son coincidencia semántica, revisión manual o ausencia de evidencia recuperada. Estos resultados expresan proximidad documental, no equivalencia factual ni cumplimiento.

3. Corpus, calidad y procedencia

3.1. Fuentes documentales

El corpus de desarrollo reúne 173 PDF: 162 procedentes de un conjunto de documentos OSHA usado durante el desarrollo y 11 publicaciones adicionales de NIOSH y OSHA. Estas últimas cubren estrés térmico, prevención de caídas, sílice respirable, riesgos químicos y equipos de protección personal. La diversidad temática permite comprobar que el sistema recupera documentos específicos y no solo términos frecuentes del dominio de seguridad laboral.

La procedencia y las condiciones de uso se documentan mediante capturas y catálogos conservados en la carpeta evidencias. Los PDF originales no se versionan en Git. Para publicaciones oficiales se conservaron evidencias de metadatos y dominio público o excepciones aplicables; para el conjunto de Kaggle se documentaron la licencia declarada y el número de archivos válidos. Esta separación entre código, índices y fuentes reduce el riesgo de redistribución involuntaria.

3.2. Auditoría y corpus canónico

La auditoría calcula dos huellas SHA-256. La primera se obtiene de los bytes del PDF y detecta copias exactas. La segunda se calcula sobre el texto extraído, convertido a minúsculas, sin números de página aislados y con espacios normalizados. Esta segunda huella detecta documentos que contienen el mismo texto aunque sus metadatos o su estructura binaria sean diferentes.

Indicador	Resultado	Interpretación
PDF analizados	173	Universo inicial del proyecto
Duplicados binarios	93	Copias exactas excluidas del índice canónico
Problemas de extracción	4	Posibles escaneados o PDF sin texto útil
Documentos canónicos	78	PDF únicos y utilizables
Fragmentos indexados	5.143	Unidades recuperables con metadatos de página

El manifiesto canónico asigna a cada documento un identificador estable de 16 caracteres. La aplicación utiliza ese identificador para aislar consultas, comparar documentos y detectar duplicados frente al corpus inicial. Los registros con texto insuficiente se mantienen en el inventario, pero no generan embeddings vacíos.

3.3. Calidad, derechos y reproducibilidad

El tratamiento del corpus responde a tres controles. Primero, calidad técnica: lectura por página, recuento de caracteres y señalización de posibles escaneados. Segundo, unicidad: hashes binario

y textual antes de indexar. Tercero, procedencia: catálogos separados para las fuentes y capturas de licencias o políticas de uso. Los informes `reports/corpus_audit.csv`, `reports/canonical_documents.csv` y `reports/extraction_problems.csv` permiten reconstruir las decisiones de inclusión y exclusión.

4. Metodología y arquitectura

4.1. Vista general

La metodología sigue un flujo de extremo a extremo. El objetivo no es entrenar un modelo desde cero, sino convertir documentos heterogéneos en un servicio de consulta controlado. Cada etapa genera un artefacto verificable: manifiestos de auditoría, fragmentos con página, embeddings, registros vectoriales, respuestas con fuentes e informes exportables.




Figura 1. Arquitectura funcional resumida del sistema.

4.2. Preparación de los documentos

pypdf extrae el texto página por página y conserva también las páginas vacías para no alterar la numeración original. Cada texto se divide aproximadamente cada 300 palabras, con 50 palabras de solapamiento. El solapamiento reduce la pérdida de contexto en los límites entre fragmentos. El ID del chunk combina el identificador documental, la página y su posición, de forma que pueda reanudarse una indexación sin duplicar elementos existentes.

El tamaño elegido es una decisión práctica: los fragmentos son suficientemente amplios para contener una recomendación o procedimiento, pero mantienen la precisión de la página. Un chunk demasiado grande puede mezclar temas; uno demasiado pequeño puede separar una condición de su consecuencia. El valor final se mantuvo constante en la evaluación para asegurar comparabilidad.

4.3. Indexación y recuperación

1. Generar el embedding normalizado de cada fragmento con BGE.
2. Guardar mediante upsert el ID, el texto, el vector y los metadatos en ChromaDB.
3. Generar el embedding de la pregunta con la instrucción de consulta de BGE.
4. Aplicar, si procede, un filtro por identificador documental.
5. Recuperar candidatos, deduplicar chunks y limitar la contribución de cada PDF.
6. Entregar al servicio de análisis una lista ordenada con texto, archivo, página, distancia y similitud.

ChromaDB usa espacio coseno. Como los vectores están normalizados, la distancia se transforma en similitud mediante $1 - \text{distancia}$. La aplicación presenta la distancia para conservar coherencia con el resultado nativo de la base vectorial y utiliza la similitud en los informes comparativos.

4.4. Ingesta dinámica y consistencia

La ingesta dinámica permite incorporar un PDF sin reconstruir todo el corpus. Antes de generar embeddings comprueba el hash binario y el textual tanto en el manifiesto canónico como en el registro de documentos cargados. Si existe una coincidencia, devuelve el documento ya representado. Si el archivo es nuevo, lo copia a data/uploads, genera chunks, actualiza ChromaDB y crea un registro SQLite.

La operación utiliza rollback ante fallos posteriores al copiado o a la indexación. El registro guarda estado, número de páginas, número de fragmentos, tipo documental, función en el análisis y metadatos de procedencia. Una prueba de humo crea un PDF temporal, verifica su recuperación aislada y elimina tanto los chunks como el registro al finalizar.

Resultado de ingesta	Significado	Acción
duplicate_file	Mismo SHA-256 binario	Reutilizar el documento existente
duplicate_text	Texto normalizado idéntico	Reutilizar el documento existente
needs_ocr	Sin texto útil	Registrar; no indexar hasta aplicar OCR
indexed	PDF válido y nuevo	Copiar, indexar y registrar

4.5. Trazabilidad y controles contra respuestas no fundamentadas

Cada resultado conserva dos niveles de trazabilidad. El nivel generativo indica qué etiquetas [Sx] afirma haber utilizado el LLM. El nivel determinista muestra todas las fuentes recuperadas a partir de los metadatos originales. La evaluación comprueba que las etiquetas citadas existan y que ningún fragmento proceda de un documento no autorizado.

Para preguntas fuera del ámbito del documento, el prompt solicita una respuesta explícita de ausencia. El sistema no bloquea por una distancia fija porque el significado de esa distancia cambia entre consultas; en su lugar combina aislamiento documental, evidencia mostrada y evaluación de abstención. En un entorno productivo, este control podría complementarse con un umbral calibrado y revisión humana.

5. Implementación y experiencia de uso

5.1. Componentes principales

Capa	Tecnología	Responsabilidad
Carga	pypdf	Extracción por página y conservación de numeración
Representación	BGE + sentence-transformers	Embeddings normalizados de 768 dimensiones
Persistencia semántica	ChromaDB	Vectores, textos, metadatos y filtros

Capa	Tecnología	Responsabilidad
Generación	Qwen2.5-3B-Instruct	Respuestas y síntesis basadas en evidencias
Registro	SQLite	Estado y metadatos de ingestas dinámicas
Interfaz	Streamlit	Navegación, formularios, resultados y descargas

El código se organiza por responsabilidades: loaders, embeddings, vector_db, retrieval, llm, analysis, ingestion y registry. Los puntos de entrada de terminal —ask.py, compare.py, check_coverage.py e ingest.py— facilitan pruebas reproducibles. app.py reutiliza esos servicios en lugar de duplicar la lógica de negocio.

5.2. Interfaz Streamlit

La interfaz está organizada en seis vistas: Inicio, Cargar PDF, Preguntar, Comparar, Cobertura y Registro. La página inicial muestra el tamaño del corpus y las funciones disponibles. Las vistas de análisis comparten un catálogo documental que identifica cada opción con nombre, origen y ID canónico. Esto explica etiquetas como «2016-106.pdf [corpus] · 32247ef05a6ebfdb»: el texto combina un nombre comprensible con un identificador estable usado internamente.




Figura 2. Página de inicio y estado del corpus.

La navegación está pensada para que una persona no técnica pueda ejecutar el flujo sin usar comandos. Los textos de ayuda advierten que la cobertura es semántica y que el sistema no certifica cumplimiento. Las tablas de fuentes muestran archivo, página, chunk y distancia, y los informes de comparación y cobertura pueden descargarse en Markdown.

5.3. Preguntas documentales

La persona usuaria puede consultar todo el corpus o seleccionar uno o varios PDF. El número máximo de evidencias es configurable. La respuesta se muestra junto con las fuentes recuperadas, independientemente de cuáles cite el LLM. En la prueba sobre 2016-106.pdf, el sistema sintetizó formación, hidratación, descanso y aclimatación y vinculó la respuesta con páginas concretas del documento.

Preguntas documentales »

Ámbito de la consulta
☒ Todo el corpus ☐ Documentos seleccionados

Pregunta
 Ejemplo: What preventive measures are recommended to protect workers from heat stress?

Número máximo de evidencias
 3

Respuesta

ANSWER: Employers should implement the following measures to protect workers from heat stress:

- [S1] Employers should train workers on recognizing symptoms of heat-related illness, proper hydration, and the care and use of heat-protective clothing and equipment.
- [S1] Employers should have an acclimatization plan for new and returning workers, as lack of acclimatization has been shown to be a major factor associated with worker heat-related illness and death.
- [S1] Employers should provide means for appropriate hydration and encourage workers to hydrate themselves with potable water <15°C (59°F) made accessible near the work area.
- [S1] Employers should implement a work/rest schedule and provide a cool area (e.g., air-conditioned or shaded) for workers to rest and recover.
- [S2] Employers should limit the time workers spend each day in the hot environment by decreasing exposure time in the hot environment and/or increasing recovery time spent in a cool environment.
- [S2] Employers should reduce the metabolic demands of the job by such procedures as mechanization, the use of special tools, or an increase in the number of workers per task.
- [S2] Employers should increase heat tolerance by instituting a heat acclimatization plan and by increasing physical fitness.
- [S2] Employers should train supervisors and workers to recognize early signs and symptoms of heat illnesses and to administer relevant first aid procedures.
- [S2] Employers should implement a buddy system in which workers are responsible for observing fellow workers for early signs and symptoms of heat intolerance.
- [S2] Employers should provide adequate amounts of cool (i.e., less than 13°C (56°F)), potable water near the work area and encourage workers to drink a cup of water (about 8 oz.) every 15 to 20 minutes.

SOURCES USED: S1, S2

Fuentes recuperadas

Fuente	Documento	Archivo	Página	Chunk	Distancia	
S1		2010-106.pdf		10	0	0.2229
S2		2016-106.pdf		33	0	0.2305
S3		2016-106.pdf		41	1	0.2306

Figura 3. Respuesta documental con etiquetas de fuente y tabla de evidencias.

5.4. Comparación de documentos

La comparación exige exactamente dos documentos y un enfoque temático. Recupera evidencias de ambos, calcula una similitud global y solicita al LLM un análisis separado de propósito, riesgos, medidas, responsabilidades e información no determinable. El informe identifica cada evidencia con una etiqueta [Sx], la página y el chunk. En el caso 2010-114 frente a 2016-106, la similitud global fue 0,8560 para el enfoque de estrés térmico, síntomas, primeros auxilios y prevención. (ver la Figura D.3 en el Anexo D).

El valor no significa que los documentos sean intercambiables. El folleto breve 2010-114 explica riesgos y primeros auxilios, mientras que 2016-106 ofrece un tratamiento ocupacional más amplio, con formación, supervisión y seguimiento médico. Esta diferencia ilustra por qué la similitud debe leerse junto con las evidencias y no como una conclusión aislada.

5.5. Preevaluación de cobertura

La cobertura toma un documento de referencia y otro evaluado. Para cada evidencia recuperada de la referencia busca la evidencia evaluada más próxima y aplica dos umbrales: coincidencia, revisión o ausencia. En el ejemplo 2016-106 como referencia y 2010-114 como evaluado, cuatro de cuatro evidencias superaron el umbral, con cobertura semántica del 100 % y similitud global de 0,8284. (ver la Figura D.4 en el Anexo D).

La lectura cualitativa revela la limitación del porcentaje: algunas evidencias de referencia trataban seguimiento médico y responsabilidades del empleador, mientras que el folleto evaluado describía riesgos y primeros auxilios de forma general. La proximidad temática permitió superar el umbral, pero no demostró una cobertura equivalente. Por ello, el informe incluye el texto de ambos fragmentos y exige revisión competente.

INTERPRETACIÓN OBLIGATORIA

Un 100 % de cobertura semántica significa que cada evidencia de referencia recuperada encontró un fragmento próximo sobre el umbral. No significa que el documento evaluado cumpla todos los requisitos ni que contenga el mismo nivel de detalle.

6. Evaluación

6.1. Diseño experimental

Se realizaron dos evaluaciones reproducibles. La primera analizó la calidad del ranking documental mediante 11 consultas curadas sobre 11 publicaciones de NIOSH y OSHA. Para ello, se utilizó la misma función de recuperación empleada en producción, incluida la instrucción de consulta del modelo BGE, y se limitó el resultado a un máximo de un fragmento por PDF. La segunda evaluación analizó seis respuestas generadas por el sistema RAG: cinco correspondientes a preguntas factuales y una a una consulta fuera del dominio, todas restringidas a un documento específico.

La relevancia documental se estableció a partir de los títulos y las materias previamente identificadas, no de interpretaciones legales. Las métricas del sistema RAG verificaron la generación de una respuesta no vacía, el aislamiento documental, la presencia y validez de las etiquetas de las fuentes, la cobertura de los conceptos esperados, la capacidad de abstención y la aceptación automática. Los scripts de evaluación y los archivos CSV con los resultados forman parte del repositorio.

Las pruebas se ejecutaron localmente en un equipo con un procesador Intel Core i7-14650HX, 32 GB de memoria RAM y Microsoft Windows 11 Home, versión 10.0.26200. La inferencia de los modelos se realizó exclusivamente mediante CPU, sin aceleración CUDA. Esta configuración debe tenerse en cuenta al interpretar los resultados de latencia, especialmente los correspondientes a la generación local de respuestas.

6.2. Resultados del retrieval

Métrica	Resultado	Lectura
Hit@1	90,91 %	10 de 11 consultas aciertan en primera posición
Hit@3 / Hit@5	100,00 %	Todos los documentos relevantes aparecen antes del rango 3
MRR@5	0,9545	El primer resultado relevante aparece muy arriba
Precision@5 media	0,2364	Limitada por el número de relevantes etiquetados
Precision@5 normalizada	1,0000	Máximo alcanzable bajo la definición de relevancia
Recall@5 medio	1,0000	Se recuperan todos los relevantes anotados
Latencia media	0,0927 s	Recuperación vectorial rápida

La única consulta cuyo primer relevante apareció en segunda posición fue la relativa a caídas en construcción. El resultado superior pertenecía a un documento temáticamente próximo sobre parapetos de cubierta. Por tanto, el fallo de Hit@1 no representa una recuperación irrelevante, sino una confusión razonable dentro de una familia documental cercana.

La Precision@5 bruta requiere especial cautela. La mayoría de las consultas solo tienen un PDF marcado como relevante; por definición, incluso un ranking perfecto no puede superar 0,20 en esos casos. La precisión máxima media del benchmark es 0,2364, exactamente el valor obtenido. La

versión normalizada facilita esta lectura, pero no sustituye una colección de juicios de relevancia más amplia.

6.3. Resultados de respuestas RAG

Métrica	Resultado
Respuestas no vacías	100,00 %
Aislamiento documental	100,00 %
Presencia de etiquetas de fuente	100,00 %
Validez de etiquetas	100,00 %
Cobertura conceptual media	95,00 %
Abstención correcta	100,00 %
Aceptación automática	100,00 %
Latencia media extremo a extremo	113,92 s

Los resultados confirman que las respuestas se mantuvieron dentro del documento autorizado y utilizaron etiquetas válidas. El caso fuera del dominio preguntó por un algoritmo de cifrado y longitud de contraseña en un folleto de estrés térmico; el modelo indicó correctamente que el documento no contenía esa información. La cobertura conceptual del 95 % refleja que las respuestas incluyeron casi todos los conceptos esperados, pero no evalúa exhaustivamente redacción, utilidad o exactitud factual frase a frase.

Las pruebas de generación se ejecutaron localmente en un equipo con procesador Intel Core i7-14650HX, 32 GB de memoria RAM —31,7 GB detectados por el sistema— y Microsoft Windows 11 Home, versión 10.0.26200. La inferencia se realizó exclusivamente mediante CPU, ya que no se dispuso de aceleración CUDA ni de una GPU compatible. Por tanto, la latencia media de generación de 113,92 segundos corresponde a este entorno concreto de ejecución y representa la principal limitación operativa del prototipo. Este resultado no debe extrapolarse directamente a equipos dotados de aceleración mediante GPU.

6.4. Interpretación conjunta

El retrieval es suficientemente rápido para una interacción fluida y sitúa la evidencia relevante en las primeras posiciones. La generación local aporta síntesis y lenguaje natural, pero domina el tiempo de respuesta. Esto sugiere dos modos de uso: una vista inmediata de evidencias para búsquedas rápidas y una respuesta generada opcional cuando la persona necesita una síntesis. La arquitectura ya separa ambas etapas, por lo que esta mejora no exige rediseñar el índice.

Las métricas también muestran que el principal valor del sistema no es solo responder, sino controlar el ámbito y hacer visibles las fuentes. Un modelo más grande podría mejorar la redacción, pero sin metadatos de página, filtros e informes deterministas seguiría siendo difícil auditar la salida.

7. Discusión

7.1. Aportaciones

- Pipeline completo desde la auditoría del corpus hasta una interfaz operativa.
- Deduplicación en dos niveles y manifiesto canónico reproducible.
- Trazabilidad estable a archivo, página y chunk en todas las funciones.
- Aislamiento de consultas por documento y verificación de fuentes autorizadas.
- Comparación y cobertura con exportación y advertencias de interpretación.
- Ingesta incremental con SQLite, rollback y detección de OCR pendiente.
- Evaluaciones separadas para ranking y generación, con resultados versionados.

Desde una perspectiva de negocio, el prototipo reduce el tiempo de localización de evidencia y ofrece un punto de acceso común a funciones que normalmente requerirían scripts separados. La aplicación puede ejecutarse de manera local, lo que facilita trabajar con documentación que no debe enviarse a servicios externos. La arquitectura modular permite sustituir el modelo generativo o la interfaz sin reconstruir el corpus.

7.2. Limitaciones y amenazas a la validez

- El benchmark es reducido y sus consultas fueron curadas manualmente sobre once publicaciones.
- La evaluación de conceptos no equivale a una revisión humana exhaustiva de factualidad.
- El corpus está centrado en inglés y en seguridad y salud ocupacional.
- Los PDF escaneados se detectan, pero aún no se procesan mediante OCR.
- La latencia del LLM en CPU limita la interacción cuando se requiere respuesta inmediata.
- Una similitud alta puede corresponder a temas próximos con obligaciones o niveles de detalle distintos.
- Las condiciones de uso de cada documento deben revisarse antes de redistribuir el corpus.

La cobertura del 100 % obtenida en el caso de estrés térmico ilustra una amenaza específica: el umbral puede clasificar como coincidencia fragmentos relacionados que no expresan la misma responsabilidad. El sistema mitiga este riesgo mostrando las evidencias emparejadas y evitando el término cumplimiento. Una evolución posterior debería calibrar los umbrales con anotaciones humanas y separar requisitos atómicos antes de buscar correspondencias.

7.3. Consideraciones éticas y de uso responsable

La herramienta puede influir en decisiones sobre documentación preventiva. Por ello, debe conservar el principio de apoyo y no sustitución: las respuestas facilitan la revisión, pero la decisión corresponde a una persona competente. Las fuentes deben permanecer visibles y las exportaciones deben conservar las limitaciones. Además, los documentos cargados localmente pueden contener información sensible; en una implantación empresarial serían necesarios control de acceso, cifrado en reposo, registro de actividad y políticas de retención.

8. Conclusiones y líneas futuras

El proyecto demuestra que es posible construir un sistema documental local, reproducible y trazable combinando embeddings BGE, ChromaDB y un LLM de tamaño moderado. La solución final procesa 78 documentos canónicos y 5.143 fragmentos, responde sobre ámbitos seleccionados, compara PDF, preevalúa cobertura e incorpora nuevos archivos sin reconstruir el índice. La interfaz Streamlit convierte estos componentes en una aplicación utilizable, y los informes Markdown facilitan conservar evidencias.

Los resultados de retrieval muestran un ranking sólido: Hit@1 del 90,91 % y recuperación completa antes de las tres primeras posiciones. La evaluación RAG confirma aislamiento y trazabilidad de fuentes, con 95 % de cobertura conceptual y abstención correcta. La principal restricción es la latencia de generación local en CPU, no la recuperación vectorial.

Como líneas futuras se proponen integrar OCR, ampliar la evaluación humana y multilingüe, calibrar umbrales por tipo de documento, incorporar reranking, añadir autenticación y auditoría, y ofrecer un modo de solo evidencias para respuestas inmediatas. También sería útil representar requisitos de referencia como unidades atómicas para diferenciar coincidencia temática de cobertura sustantiva.

La contribución principal no reside en un único modelo, sino en la combinación de controles que permiten explicar el resultado: corpus canónico, metadatos, filtros, fuentes deterministas, advertencias y evaluación reproducible. Esa combinación convierte una demostración de RAG en un prototipo técnico defendible y susceptible de evolución hacia un servicio documental empresarial.

Bibliografía y referencias

- [1] Lewis, P., Perez, E., Piktus, A., et al. (2020). Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. *Advances in Neural Information Processing Systems*, 33, 9459-9474. arXiv:2005.11401.
- [2] Xiao, S., Liu, Z., Zhang, P. y Muennighoff, N. (2023). C-Pack: Packaged Resources to Advance General Chinese Embedding. arXiv:2309.07597.
- [3] Qwen Team (2024). Qwen2.5 Technical Report. arXiv:2412.15115.
- [4] Beijing Academy of Artificial Intelligence (BAAI) (2023). BGE-base-en-v1.5 [ficha de modelo]. Hugging Face. BAAI/bge-base-en-v1.5 (consulta: 01-09-2026).
- [5] Qwen Team (2024). Qwen2.5-0.5B-Instruct [ficha de modelo]. Hugging Face. Qwen/Qwen2.5-0.5B-Instruct (consulta: 01-09-2026).
- [6] Chroma (s. f.). Chroma documentation: Collections and querying. Documentación oficial de Chroma (consulta: 01-09-2026).
- [7] Streamlit (s. f.). Streamlit documentation. Documentación oficial de Streamlit (consulta: 01-09-2026).
- [8] National Institute for Occupational Safety and Health (NIOSH) (2016). Criteria for a Recommended Standard: Occupational Exposure to Heat and Hot Environments. DHHS (NIOSH) Publication No. 2016-106. CDC/NIOSH.
- [9] aminhaghiii (s. f.). All OSHA PDFs [conjunto de datos]. Kaggle. Kaggle: All OSHA PDF (consulta: 27-08-2026).

Anexos

El código fuente del prototipo y los scripts empleados para reproducir las evaluaciones están disponibles en el repositorio [TFM_Documental_AI](https://github.com/Alejandra-Romero-G/TFM_Documental_AI). La implementación descrita y evaluada en esta memoria corresponde a la versión estable v1.0.0.

Los anexos reúnen las instrucciones de instalación y reproducción, ejemplos de ejecución, resultados detallados y evidencias técnicas del proyecto.

Anexo A. Instalación, reproducción y evaluación

A.1. Obtención del código fuente

El código fuente correspondiente a la versión estable v1.0.1 puede descargarse desde GitHub mediante los siguientes comandos:

```
git clone --branch v1.0.1 https://github.com/Alejandra-Romero-G/TFM_Documental_AI.git
cd TFM_Documental_AI
```

El repositorio no incluye los documentos PDF originales, la base de datos vectorial ni el registro SQLite. Para reconstruir el sistema deben obtenerse los documentos siguiendo la información de procedencia recogida en docs/Fuente.md y colocarse bajo data/documents/.

La estructura esperada es:

data/

```
└── documents/
    ├── Niosh/
    └── osha/
```

A.2. Instalación en Microsoft Windows

Los siguientes comandos deben ejecutarse desde PowerShell, dentro de la carpeta del proyecto:

```
python -m venv .venv
.\.venv\Scripts\Activate.ps1
python -m pip install --upgrade pip
python -m pip install -r requirements.txt
python -m pip check
```

Si el comando python no está disponible, puede emplearse el lanzador de Python para Windows:

```
py -3.13 -m venv .venv
.\.venv\Scripts\Activate.ps1
```

A.3. Instalación en Ubuntu GNU/Linux

En Ubuntu, el entorno virtual se crea y activa mediante los siguientes comandos:

```
python3 --version
python3 -m venv .venv
source .venv/bin/activate
python -m pip install --upgrade pip
python -m pip install -r requirements.txt
python -m pip check
```

Si Ubuntu indica que el módulo venv no está disponible, debe instalarse previamente:

```
sudo apt update
sudo apt install python3-venv python3-pip
```

Si se dispone específicamente de Python 3.13, el entorno también puede crearse mediante:

```
python3.13 -m venv .venv
source .venv/bin/activate
```

A.4. Auditoría e indexación

Una vez colocados los PDF bajo data/documents/, se debe ejecutar nuevamente la auditoría en el ordenador de destino. Este paso regenera el manifiesto documental empleando rutas compatibles con el sistema operativo utilizado.

```
python scripts/audit_corpus.py
python scripts/index_corpus_bge.py --dry-run
python scripts/index_corpus_bge.py
```

La primera ejecución del indexador descarga el modelo BAAI/bge-base-en-v1.5 y construye la colección vectorial persistente en data/chroma/. No es necesario copiar el entorno virtual ni la colección ChromaDB desde el ordenador original, ya que ambos elementos pueden reconstruirse.

A.5. Ejecución de la aplicación

La interfaz se inicia mediante:

```
python -m streamlit run app.py
```

Una vez iniciado el servidor, la aplicación puede abrirse normalmente en:

```
http://localhost:8501
```

A.6. Ejecución de las evaluaciones

Las evaluaciones pueden reproducirse mediante:

```
python tests/evaluate_retrieval.py
python tests/evaluate_rag_grounding.py
python tests/smoke_test_dynamic_ingestion.py
```

La evaluación RAG utiliza el modelo generativo local y puede necesitar varios minutos cuando se ejecuta exclusivamente mediante CPU.

A.7. Entorno utilizado para la evaluación final

Elemento	Especificación
Procesador	Intel Core i7-14650HX
Memoria RAM	32 GB instalados (31,7 GB detectados)
Sistema operativo	Microsoft Windows 11 Home, versión 10.0.26200
Versión de Python	Python 3.13.12
Aceleración	No disponible; ejecución exclusivamente mediante CPU
Fecha de la ejecución final	1 de septiembre de 2026, 15:23 h

Las evaluaciones de recuperación documental y generación RAG se ejecutaron localmente en el entorno descrito, sin aceleración mediante GPU. Los resultados completos se almacenaron en `reports/evaluation/retrieval_bge_results.csv` y `reports/evaluation/rag_grounding_results.csv`.

La reproducción en otro sistema operativo puede producir diferencias en los tiempos de ejecución, especialmente durante la generación local. Por este motivo, la latencia de 113,92 segundos debe interpretarse en relación con el equipo y el entorno indicados.

Anexo B. Ejemplos de uso

Los comandos siguientes utilizan rutas con / y se presentan en una sola línea, por lo que pueden ejecutarse tanto en Windows PowerShell como en Ubuntu después de activar el entorno virtual.

B.1. Pregunta restringida a un documento

```
python ask.py --document 2016-106.pdf "What training and preventive measures should employers provide?"
```

B.2. Comparación documental

```
python compare.py 2010-114.pdf 2016-106.pdf --focus "heat stress hazards, symptoms, first aid and preventive measures" --chunks-per-document 4 --threshold 0.65 --output reports/comparisons/2010-114_vs_2016-106.md
```

B.3. Evaluación de cobertura documental

```
python check_coverage.py 2016-106.pdf 2010-114.pdf --focus "heat stress hazards, first aid, preventive measures and employer responsibilities" --n-results 4 --match-threshold 0.65 --review-threshold 0.55 --output reports/coverage/2010-114_against_2016-106.md
```

B.4. Ingesta en modo de validación

```
python ingest.py ruta/documento.pdf --document-type report --analysis-role target --source-name "Organización" --dry-run
```

El modo `--dry-run` valida el documento, extrae su contenido y comprueba posibles duplicados sin copiarlo, registrarlo ni incorporarlo a ChromaDB.

Anexo C. Evidencias y artefactos

Artefacto	Finalidad
reports/corpus_audit.csv	Inventario completo y resultado de extracción
reports/canonical_documents.csv	Manifiesto del corpus canónico
reports/extraction_problems.csv	PDF que requieren revisión u OCR
reports/evaluation/retrieval_bge_results.csv	Detalle de ranking por consulta
reports/evaluation/rag_grounding_results.csv	Detalle de respuestas y métricas
evidencias/02_licencias/	Capturas de metadatos, licencias y dominio público
evidencias/reports/	Catálogos de procedencia de las fuentes

Anexo D. Capturas de la interfaz y ejemplos de funcionamiento

Este anexo presenta las principales vistas de la interfaz desarrollada con Streamlit y algunos ejemplos de los resultados obtenidos durante las pruebas funcionales del prototipo.



Figura D.1. Página de inicio y estado del corpus.




Figura D.2. Cargar archivo y detección de un PDF duplicado





Figura D.2. Resultado de Consulta documental y respuesta con Fuentes: elaboración propia mediante el prototipo desarrollado, versión v1.0.0.






Figura D.4. Resultado de la preevaluación de cobertura entre 2016-106.pdf, utilizado como documento de referencia, y 2010-114.pdf, utilizado como documento evaluado. Fuente: elaboración propia mediante el prototipo desarrollado, versión v1.0.0.

Anexo E. Enlaces a los entregables digitales

Este anexo reúne los enlaces de acceso a los principales entregables digitales del proyecto: el código fuente y la versión estable del sistema, publicados en GitHub, y el vídeo de presentación.

Recurso	Descripción	Enlace de acceso
Repositorio de GitHub	Código fuente, documentación técnica, scripts de evaluación y evidencias del proyecto.	https://github.com/Alejandra-Romero-G/TFM_Documental_AI
Versión estable v1.0.1	Versión final depurada empleada como referencia para la memoria y la entrega.	https://github.com/Alejandra-Romero-G/TFM_Documental_AI/tree/v1.0.1
Vídeo de presentación	Presentación breve del objetivo, la arquitectura, las funciones principales y los resultados del prototipo.	https://youtu.be/8zDdUW1-U2o

Nota sobre el acceso y la reproducibilidad

El repositorio no incluye los documentos PDF originales, la colección local de ChromaDB ni el registro SQLite. La procedencia de las fuentes, las dependencias y las instrucciones necesarias para reconstruir el entorno se encuentran documentadas en el propio repositorio.